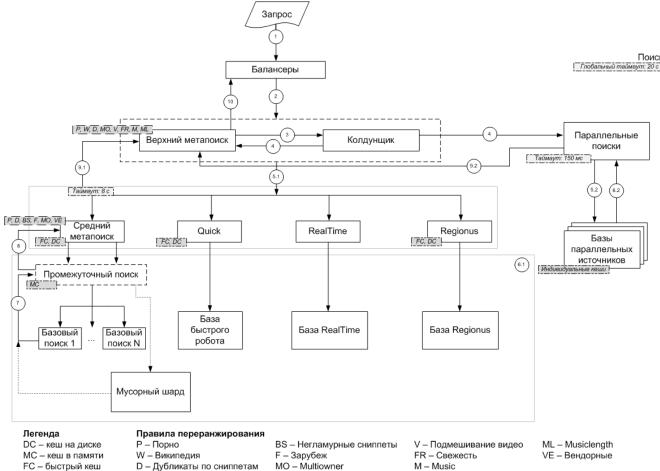
Разработка алгоритма для выделения частовстречающихся программ	шаблонов ошибок из log-файлов
1	

Оглавление

B	Введение		3
1	Ана	ализ предметной области	5
	1.1	Представление задачи в терминах MapReduce	. 5
	1.2	Выбор языка программирования и средств разработки	. 5
	1.3	Структура данных	
	1.4	Стадии выполнения задачи	
		1.4.1 Подготовка репозитория	. 6
		1.4.2 Выбор хранилища для паттернов	
		1.4.3 Написание программного кода	. 7
2	Им	плементация задачи	8
	2.1	Диаграмма компонентов	. 8
	2.2	Описание способов запуска	. 8
	2.3	Анализ полученных результатов	. 8
3	Дал	льнейшее развитие	9
38	клю	очение	10

Введение

Большинство программных систем, имеющих сложную структуру и состоящих из нескольких сотен различных компонент, обладают рядом схожих проблем. Например веб-поиск содержит следующие компоненты: балансеры, верхние, средние метапоиски, промежуточные и базовые поиски, колдунщики, антироботы, свежесть, региональные поиск, несколько десятков параллельных поисков. Краткое схематичное описание архитектуры:



Всего единовременно запущено несколько ******** тысяч инстансов 1 приложений. Каждый инстанс генерирует множество ошибок и записывает каждую из них в log-файл.

Некоторые приложения, близкие по функционалу, пишут в один и тот же файл. Log-файлы ротируются согласно определённому алгоритму. Тем не менее объем log-файла для одного инстанса может достигать нескольких сотен мегабайт, что препятствует быстрому ручному анализу в случае инцидента и инженеры вынуждены тратить ценные секунды на просмотр сотен тысяч строк файла в поисках сообщения с описанием элемента, вызвавшего сбой работы системы.

Начальным требованием к системе для эффективного использования алгоритма является наличие сопоставимого с количеством поисковых приложений количества нод на которых может быть запущена программа, реализующая алгоритм.

В организации, в которой выполнялась учебно-исследовательская работа, развёрнута боль-

¹инстанс — приложение, запущенное в контейнере и описываемое парой host:port

шая поисковая инфраструктура, которая не лишена недостатков и существует вероятность поломки некоторой её части. Существует множество средств мониторинга состояния вебпоиска и противодействия инцидентам, но в некоторых случаях инженерам их недостаточно и приходится вручную анализировать log-файлы отдельных инстансов приложений на отдельных host'ах, что, в свою очередь, замедляет скорость реакции на непредвиденную ситуацию. Но даже автоматизация процесса анализа log-файла на одного инстанса не решает проблему полностью, поэтому необходима возможность быстрого анализа log-файлов сразу множества инстансов.

Таким образом, целью этой учебно-исследовательской работы является разработка алгоритма, позволяющего собирать статистику по ошибкам, встречающимся в log-файлах инстансов поисковых приложений на основе существующих шаблонов и выделять новые шаблоны.

Глава 1

Анализ предметной области

1.1 Представление задачи в терминах MapReduce

Для распределённого запуска приложений была выбрана модель распределённых вычислений MapReduce¹ по ряду причин.

Как оказалось задача без особых сложностей выражается в терминах чистых функций flat map и flat reduce, так как основная структура, используемая в алгоритме — это пара(паттерн², количество совпадений) и благодаря этому однопоточный код легко запускается на множестве нод MapReduce-кластера. Это обстоятельство освобождает от реализации сложного механизма сетевого взаимодействия.

В качестве реализации модели MapReduce была выбрана реализация Yandex Tables. Код программы, реализующий алгоритм легко переносится на другие реализации данной модели распределённых вычислений.

1.2 Выбор языка программирования и средств разработ-ки

В качестве среды разработки было решено использовать удалённую виртуальную машину с конфигурацией и окружением идентичными конфигурации и окружению MapReduce ноды. Были выбраны следующие программные продукты:

- В качестве операционной системы использовался дистрибутив GNU/Linux Ubuntu 12.04 LTS с модифицированным ядром и дополнительными пакетами.
- Vim один из немногих несуществующих настоящих текстовых редакторов, обладающих массой встроенных возможностей и практически безграничным потенциалом к расширению за счёт встроенного интерпретируемого языка программирования VimL и поддержкой возможности написания расширений на таких языках, как python, ruby, perl.
- Сохранение состояние рабочего окружения осуществлялось с помощью терминального мультиплексора tmux, имеющего клиент-серверную архитектуру и позволяющего отсоединятся от текущей сессии, оставляя её работать в фоновом режиме с последующей возможностью переподключения. tmux свободная консольная утилита-мультиплексор, предоставляющая пользователю доступ к нескольким терминалам в рамках одного экрана. tmux может быть отключён от экрана: в этом случае он продолжит исполняться

¹МарReduce — модель распределённых вычислений, представленная компанией Google, используемая для параллельных вычислений над очень большими, несколько петабайт, наборами данных в компьютерных кластерах.

²паттерн — регулярное выражение

в фоновом режиме; имеется возможность вновь подключиться к tmux, находящемуся в фоне. tmux является штатным мультиплексором терминалов операционной системы OpenBSD. Программа tmux задумывалась как замена программы GNU Screen.

- Удалённое подключение осуществлялось средствами защищённого протокола ssh (беспарольная аутентификация с использованием ключа) и технологии cauth. SSH (англ. Secure Shell "безопасная оболочка"]) сетевой протокол прикладного уровня, позволяющий производить удалённое управление операционной системой и туннелирование TCP-соединений (например, для передачи файлов). Схож по функциональности с протоколами Telnet и rlogin, но, в отличие от них, шифрует весь трафик, включая и передаваемые пароли. SSH допускает выбор различных алгоритмов шифрования. SSH-клиенты и SSH-серверы доступны для большинства сетевых операционных систем.
- Для управления версиями исходных кодов использовалась децентрализованная система управления версиями git, в качестве hosting-провайдера был использован сервис github

В качестве языка программирования был выбран python2.7. Так как:

- Он предустановлен в большинстве современных дистрибутивах операционных систем.
- Выразителен. Аналогичные программы на таких языках как Java, C++ имеют в разы большие объёмы исходных кодов.
- Обладает высокой производительностью.
- Имеет множество библиотек, в том числе библиотеки для работы с регулярными выражениями, обёртки для MapReduce.

1.3 Структура данных

В качестве входных данных использовался агрегированный log-файл с нерегулярной структурой, содержащий сообщения об ошибках в различных форматах, как многострочные, так и однострочные.

Первая часть алгоритма, позволяет осуществить сбор статистики и возвращает список пар (паттерн, количество совпадений), так же существует возможность получить часть текста не удовлетворяющую известным паттернам, для последующего анализа с помощью второй части алгоритма, позволяющей выделить новые предполагаемые паттерны и с помощью первой части алгоритма получить статистику, подтверждающую или опровергающую предположение.

1.4 Стадии выполнения задачи

1.4.1 Подготовка репозитория

Был создан git-репозиторий на сервисе github, сделана его локальная копия. Была выбрана следующая структура проекта и правила именования файлов:

- В корневом каталоге лежат файлы README.md, LICENSE, .gitignore.
- В каталоге doc/ хранится документация. Исходные тексты в L^AT_EXи скомпилированная версия в PDF.
- В каталоге direlog/ хранятся исходные коды с расширением .py и тесты, имеющие префикс test
- В каталоге direlog/example/ хранятся примеры log-файлов и вспомогательные скрипты на языке bash.

1.4.2 Выбор хранилища для паттернов

В качестве хранилища для паттернов было решено использовать обычный файл на языке python, названный patterns.py и содержащий в себе два списка паттернов prepare_patterns и main_patterns, используемых на подготовительном этапе и на этапе сбора статистики соответственно, и хранить его под контролем версий в этом же репозитории. Причин на это несколько: во-первых простота модификации файла с помощью скриптов, во-вторых возможность просмотра истории изменений и откат к предыдущим версиям, в-третьих возможность ручного редактирования.

1.4.3 Написание программного кода

Написание программного кода было разделено на несколько этапов.

- 1 Написание утилиты для предварительной обработки исходного log-файла. Утилита получила название prepare.py и позволила подготовить сырой log-файл для последующей обработки, путём замены уникальных токенов, таких как UUID, timestamp, версии, номера строк, пути, содержащие версии, на строковые константы.
- 2 Формирование prepare patterns на основе ручного анализа log-файлов.
- 3 Написание функциональных тестов для prepare.py.
- 4 Реализация алгоритма для сбора статистики с использованием main_patterns. Утилита получила название direlog.py. И позволяет на выходе получить список пар (паттерн, количество совпадений) или текст, не подходящий под известные паттерны.
- 5 Добавление поддержки буферизации входного потока и поддержки многострочных паттернов.
- 6 Написание функциональных тестов для direlog.py.
- 7 Добавление функции, позволяющей запускать алгоритм на MapRedcue-кластере.

Глава 2

Имплементация задачи

- 2.1 Диаграмма компонентов
- 2.2 Описание способов запуска
- 2.3 Анализ полученных результатов

Глава 3

Дальнейшее развитие

Заключение